ΠΑΝΕΠΙΣΤΗΜΙΟ ΜΑΚΕΔΟΝΙΑΣ
ΤΜΗΜΑ ΕΦΑΡΜΟΣΜΕΝΗΣ ΠΛΗΡΟΦΟΡΙΚΗΣ

Μηχανική Μάθηση

3η Εργασία – Regression problems:
Πρόβλεψη της εξέλιξης μιας ιατρικής κατάστασης

Γεωργιάνα Πετρίδου

ics23143

Επιβλέπων Καθηγητής: Ευτύχιος Πρωτοπαπαδάκης

7ο εξάμηνο | Ακαδημαϊκό Έτος: 2025 – 2026

ΠΕΡΙΕΧΟΜΕΝΑ

1. **ΕΙΣΑΓΩΓΗ**…… 3

2. **ΣΧΕΤΙΚΗ ΒΙΒΛΙΟΓΡΑΦΙΑ**…… 4

3. **ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΘΟΔΟΛΟΓΙΑ**

3.1 **ΠΕΡΙΓΡΑΦΗ DATASET**…… 5

3.2 **ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ (NaN έλεγχος, Min-Max scaling)**…….. 6

3.3 **CROSS-VALIDATION (6-fold KFold)**…… 6

3.4 **ΜΟΝΤΕΛΑ ΠΑΛΙΝΔΡΟΜΗΣΗΣ & ΥΠΕΡΠΑΡΑΜΕΤΡΟΙ** …….. 7

3.5 **ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ (RMSE,MAE,Max Error,MAP)** ……. 8

3.6 **EXPLAINABILITY ΜΕ SHAP** ……. 9

4. **ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ**

4.1 **ΠΕΙΡΑΜΑΤΙΚΗ ΔΙΑΔΙΚΑΣΙΑ**……10

4.2 **ΣΥΓΚΕΝΤΡΩΤΙΚΑ ΑΡΙΘΜΗΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ**……...10

4.3 **ΟΠΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ**……11

4.4 **ΕΡΜΗΝΕΥΣΙΜΟΤΗΤΑ ΜΕ SHAP**……..12

5. **ΣΥΜΠΕΡΑΣΜΑΤΑ**……14

6. **ΒΙΒΛΙΟΓΡΑΦΙΑ**……15

1. ΕΙΣΑΓΩΓΗ

Το πρόβλημα που εξετάζεται στην παρούσα εργασία αφορά την πρόβλεψη της εξέλιξη μιας ιατρικής κατάστασης, και συγκεκριμένα του σακχαρώδη διαβήτη, με βάση δημογραφικά και βιομηχανικά χαρακτηριστικά ασθενών. Η πρόβλεψη της πορείας μιας νόσου αποτελεί ένα σημαντικό πεδίο εφαρμογής της μηχανικής μάθησης, καθώς μπορεί να υποστηρίξει τη λήψη αποφάσεων και να συμβάλει στην καλύτερη κατανόηση των παραγόντων που επηρεάζουν την υγεία των ασθενών. Για την μελέτη του προβλήματος χρησιμοποιείται το σύνολο δεδομένων Diabetes, το οποίο περιλαμβάνει μετρήσεις σχετικές με τη φυσιολογική κατάσταση ασθενών και μια συνεχόμενη μεταβλητή στόχο που εκφράζει την εξέλιξη της νόσου ένα έτος μετά την αρχική εξέταση. Το συγκεκριμένο σύνολο δεδομένων αποτελεί ένα κλασικό παράδειγμα προβλήματος παλινδρόμησης και χρησιμοποιείται ευρέως για την αξιολόγηση αλγορίθμων μηχανικής μάθησης σε ιατρικά δεδομένα. Σκοπός της εργασίας είναι μια αναφορά που να παρουσιάζει αναλυτικά και συγκριτικά αποτελέσματα σχετικά με την ικανότητα διαφορετικών τεχνικών παλινδρόμησης να ανταπεξέλθουν στο συγκεκριμένο πρόβλημα πρόβλεψης. Για τον λόγο αυτο εξετάζονται μοντέλα διαφορετικής φύσης. Η αξιολόγηση πραγματοποιείται με χρήση 6-fold cross-validation και συστηματικής ρύθμισης υπερ παραμέτρων, ώστε να διασφαλιστεί η αξιοπιστία των αποτελεσμάτων. Η απόδοση των μοντέλων αξιολογείται με βάση πολλαπλά σφάλματα παλινδρόμησης, ενώ επιπλέον δίνεται έμφαση στην ερμηνευσιμότητα των προβλέψεων μέσω της μεθόδου SHAP. Με τον τρόπο αυτό, η εργασία δεν περιορίζεται μόνο στη σύγκριση της ακρίβειας των μοντέλων, αλλα επεκτείνεται και στην κατανόηση της συμβολής των επιμέρους χαρακτηριστικών στην διαδικασία λήψης αποφάσεων των μοντέλων.

2. ΣΧΕΤΙΚΗ ΒΙΒΛΙΟΓΡΑΦΙΑ

Η πρόβλεψη της εξέλιξης ιατρικών καταστάσεων, όπως ο σακχαρώδης διαβήτης, αποτελεί ένα από τα πιο κλασικά προβλήματα στην βιβλιογραφία της Παλινδρόμησης (Regression) και της Μηχανικής Μάθησης. Το σύνολο δεδομένων "Diabetes dataset", το οποίο χρησιμοποιείται στην παρούσα εργασία, εισήχθη αρχικά από τους **Efron et al. (2004)**. Στην έρευνά τους, οι συγγραφείς πρότειναν τη μέθοδο Least Angle Regression (LARS) και ανέδειξαν πώς δέκα βασικές δημογραφικές και βιοχημικές μεταβλητές (όπως ο δείκτης μάζας σώματος BMI και η αρτηριακή πίεση) μπορούν να μοντελοποιήσουν την πορεία της νόσου μετά από ένα έτος.

Στο πέρασμα των ετών, η έρευνα μετατοπίστηκε από τα γραμμικά μοντέλα σε πιο σύνθετους αλγορίθμους. Ο αλγόριθμος **Random Forest (Breiman, 2001)** αποτελεί πλέον σημείο αναφοράς για προβλήματα παλινδρόμησης, καθώς επιτυγχάνει υψηλή ακρίβεια διαχειριζόμενος μη γραμμικές σχέσεις και αλληλεπιδράσεις μεταξύ των χαρακτηριστικών. Παράλληλα, τα **Gaussian Processes (Rasmussen & Williams, 2006)** προσφέρουν μια ισχυρή εναλλακτική, παρέχοντας μια πιθανοτική προσέγγιση στην παλινδρόμηση, η οποία είναι ιδιαίτερα χρήσιμη σε ιατρικές εφαρμογές όπου η εκτίμηση της αβεβαιότητας είναι κρίσιμη.

Ένα από τα σημαντικότερα ζητήματα που απασχολούν τη σύγχρονη βιβλιογραφία είναι η «ερμηνευσιμότητα» (interpretability) των μοντέλων, ειδικά στον τομέα της υγείας όπου οι αποφάσεις πρέπει να είναι αιτιολογημένες. Η μέθοδος **SHAP (Lundberg & Lee, 2017)**, βασισμένη στη θεωρία παιγνίων (Shapley values), έχει καθιερωθεί ως το πρότυπο για την επεξηγήσιμη τεχνητή νοημοσύνη (XAI). Επιτρέπει την ανάλυση της συνεισφοράς κάθε μεταβλητής στην τελική πρόβλεψη, μετατρέποντας τα μοντέλα "μαύρου κουτιού" (black-box) σε κατανοητά εργαλεία για τους κλινικούς ιατρούς.

Τέλος, όσον αφορά την αξιολόγηση της ακρίβειας, ενώ μετρικές όπως το RMSE και το MAE κυριαρχούν, το **MAPE (Mean Absolute Percentage Error)** προτείνεται συχνά ως μια πιο διαισθητική μετρική. Όπως επισημαίνουν οι Hyndman & Koehler (2006), το MAPE επιτρέπει τη σύγκριση των σφαλμάτων σε ποσοστιαία κλίμακα, γεγονός που διευκολύνει την επικοινωνία των αποτελεσμάτων σε μη εξειδικευμένο κοινό, παρέχοντας μια σαφή εικόνα της σχετικής απόκλισης του μοντέλου από τις πραγματικές τιμές.

3. ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΘΟΔΟΛΟΓΙΑ

3.1 ΠΕΡΙΓΡΑΦΗ DATASET

Για την υλοποίηση της εργασίας χρησιμοποιήθηκε το σύνολο δεδομένων Diabetes, το οποίο παρέχεται από τη βιβλιοθήκη scikit-learn. Το dataset φορτώνεται με χρήση της συνάρτησης load_diabetes με τη επιλογή as_frame=True, ώστε τα δεδομένα να αναπαρίστανται σε μορφή pandas DataFrame, διευκολύνοντας την ανάλυση και την προεπεξεργασία τους. Επιπλέον, η παράμετρος scaled=False επιλέγεται ώστε τα δεδομένα να διατηρούνται στο αρχικό τους εύρος τιμών. Τα χαρακτηριστικά στο σύνολο των δεδομένων, περιλαμβάνουν μεταβλητές όπως η ηλικία (age), το φύλο (sex), ο δείκτης μάζας (bmi), η αρτηριακή πίεση (bp), καθώς και διάφορους βιομηχανικούς δείκτες αίματος (s1-s6). Η μεταβλητή στόχος (target) είναι συνεχής και εκφράζει την ποσοτική εκτίμηση της εξέλιξης της νόσου ένα έτος μετά την αρχική εξέταση.

Στο πλαίσιο της αρχικής διερεύνησης των δεδομένων,εξετάζεται το εύρος τιμών επιλεγμένων χαρακτηριστικών, όπως ο δείκτης μάζας σώματος (bmi), προκειμένου να αποκτηθεί μια πρώτη εικόνα της κλίμακας των δεδομένων. Επιπλέον, πραγματοποιείται έλεγχος για την ύπαρξη ελλειπουσών τιμών (NaN) τόσο στα χαρακτηριστικά εισόδου όσο και στη μεταβλητή στόχο (target). Παρότι στο συγκεκριμένο dataset δεν εντοπίζονται ελλειπούσες τιμές, εφαρμόσαμε προληπτικά η διαδικασία αφαίρεσης εγγράφων με NaN, ώστε να διασφαλιστεί η ορθότητα της ανάλυσης.

Για την κατανόηση της κατανομής στόχου, δημιουργείται γράφημα συχνοτήτων (histogram), το οποίο απεικονίζει τη συχνότητα εμφάνισης των τιμών της εξέλιξης της νόσου. Με αυτή την απεικόνιση έχουμε ποιοτική αξιολόγηση της κατανομής στόχου η οποία παρέχει χρήσιμη πληροφορία σχετικά με την ύπαρξη πιθανής ασυμμετρίας ή ακραίων τιμών. Τέλος, εξάγουμε και αποθηκεύουμε τα ονόματα των χαρακτηριστικών του dataset, τα οποία χρησιμοποιούνται καθ'όλη τη διάρκεια της εργασίας, τόσο στη φάση της εκπαίδευσης των μοντέλων όσο και στη διαδικασία ερμήνευσης μέσω SHAP. Με τον τρόπο αυτό διασφαλίζεται η συνεπής αντιστοίχηση των χαρακτηριστικών σε όλα τα στάδια της ανάλυσης

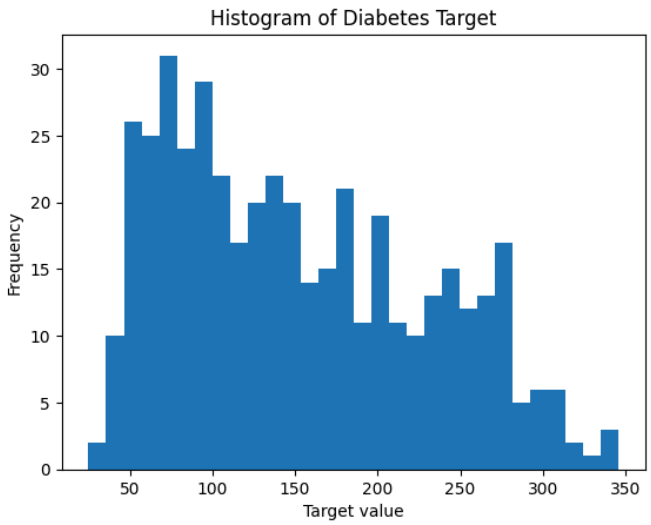

fig.1.Συχνότητα εμφάνισης των τιμών της εξέλιξης της νόσου

3.2 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ (NaN έλεγχος, Min-Max scaling)

Πριν την εκπαίδευση των μοντέλων παλινδρόμησης, εφαρμόστηκε διαδικασία προεπεξεργασίας των δεδομένων, με στόχο τη διασφάλιση της ποιότητας των δεδομένων και την βελτίωση της συγκρισιμότητας των αποτελεσμάτων. Η προεπεξεργασία περιλάμβανε τον έλεγχο για ελλιπείς τιμές (NaN) καθώς και την κανονικοποίηση των δεδομένων με χρήση Min-Max scaling. Αρχικά, πραγματοποιήθηκε έλεγχος για την ύπαρξη ελλιπών τιμών τόσο στα χαρακτηριστικά εισόδου όσο και στη μεταβλητή στόχο. Ο έλεγχος αυτός έδειξε ότι στο σύνολο των δεδομένων δεν υπήρχαν NaN τιμές. Παρόλα αυτά, για λόγους γενικότητας και καλής πρακτικής, εφαρμόστηκε η διαδικασία απομάκρυνσης τους, ώστε να διασφαλιστεί η ορθότητα της ανάλυσης.

Στη συνέχεια εφαρμόστηκε κανονικοποίηση των δεδομένων με τη χρήση της μεθόδου Min-Max scaling. Η μέθοδος αυτή μετασχηματίζει κάθε χαρακτηριστικό έτσι ώστε οι τιμές του να ανήκουν στο διάστημα [0,1], σύμφωνα με τη σχέση. Η κανονικοποίηση εφαρμόστηκε τόσο στα χαρακτηριστικά όσο και στην μεταβλητή στόχο. Η τεχνική αυτή κρίθηκε απαραίτητη καθώς τα χαρακτηριστικά του dataset βρίσκονται σε διαφορετικές κλίμακες τιμών, γεγονός που μπορεί να επηρεάσει αρνητικά την απόδοση μοντέλων που βασίζονται σε αποστάσεις ή κανονικοποιημένες ποινές, όπως οι Support Vector Regressors και τα γραμμικά μοντέλα με κανονικοποίησης.

Για την αποφυγή διαρροής πληροφορίας (data leakage), η κανονικοποίηση πραγματοποιήθηκε εντός κάθε fold της διασταυρωμένης επικύρωσης. Συγκεκριμένα, οι παράμετροι του Min-Max scaler υπολογίστηκαν αποκλειστικά στα δεδομένα εκπαίδευσης (train set) κάθε fold και στη συνέχεια εφαρμόστηκαν στα αντίστοιχα δεδομένα ελέγχου (test set). Με αυτό τον τρόπο διασφαλίζεται ότι τα δεδομένα ελέγχου δεν επηρεάζουν με κάποιον τρόπο τη διαδικασία εκπαίδευσης.

3.3 CROSS-VALIDATION (6-fold KFold)

Στο πλαίσιο της K-Fold διασταυρωμένης επικύρωσης, το σύνολο των δεδομένων χωρίζεται σε έξι(6) μη επικαλυπτόμενα υποσύνολα (folds) ίσου περίπου μεγέθους. Σε κάθε επανάληψη ένα από τα folds χρησιμοποιείται ως σύνολο ελέγχου (test set), ενώ τα υπόλοιπα πέντε folds χρησιμοποιούνται για την εκπαίδευση του μοντέλου (train set). Η διαδικασία αυτή επαναλαμβάνεται έξι φορές, έτσι ώστε κάθε εγγραφή του dataset να χρησιμοποιηθεί ακριβώς μια φορά ως δεδομένο ελέγχου. Η συγκεκριμένη προσέγγιση προσφέρει σημαντικά πλεονεκτήματα σε σχέση με ένα απλό διαχωρισμό train-test, καθώς παρέχει μια πιο σταθερή εκτίμηση για τα μοντέλα, ιδιαίτερα στο Diabetes dataset το οποίο έχει σχετικά περιορισμένο πλήθος δειγμάτων.

Η υλοποίηση της K-Fold διαδικασίας πραγματοποιήθηκε με τη χρήση της κλάσης KFold της βιβλιοθήκης sklearn.model_selection. Για λόγους αναπαραγωγιμότητας των πειραμάτων, χρησιμοποιήθηκε σταθερός σπόρος τυχαιότητας (random seed), ενώ ενεργοποιήθηκε και η τυχαία αναδιάταξη (shuffle) των δεδομένων πριν τον διαχωρισμό σε folds. Το K-Fold setup παρήγαγε δείκτες (indices) που καθορίζουν ποιες γραμμές του dataset ανήκουν στο train και στο test set σε κάθε fold, χωρίς να πραγματοποιείται αντιγραφή των δεδομένων. Επιπλέον, όλες οι διαδικασίες εκπαίδευσης, κανονικοποίησης και αξιολόγησης εκτελέστηκαν εντός κάθε fold, για να μπορούμε να διασφαλίσουμε ότι τα δεδομένα ελέγχου θα παραμείνουν πλήρως ανεξάρτητα από την διαδικασία εκπαίδευσης και να μην υπάρξη κάποια διαρροή πληροφορίας.

3.4 ΜΟΝΤΕΛΑ ΠΑΛΙΝΔΡΟΜΗΣΗΣ & ΥΠΕΡΠΑΡΑΜΕΤΡΟΙ

Στην παρούσα εργασία εξετάστηκε η απόδοση τεσσάρων διαφορετικών μοντέλων παλινδρόμησης, τα οποία αντιπροσωπεύουν τόσο γραμμικές όσο και μη γραμμικές προσεγγίσεις στη μηχανική μάθηση. Στόχος ήταν η συγκριτική αξιολόγηση των μοντέλων ως προς την ικανότητα τους να προβλέπουν την εξέλιξη της νόσου του διαβήτη με βάση τα διαθέσιμα δημογραφικά και βιομηχανικά χαρακτηριστικά.

- **Random Forest Regressor:** είναι ένα σύνολο δέντρων απόφασης που μπορεί να μοντελοποιήσει πολύπλοκες μη γραμμικές σχέσεις και αλληλεπιδράσεις μεταξύ των χαρακτηριστικών.

- **Gaussian Process Regressor:** παρέχει μια πιθανοτική προσέγγιση στην παλινδρόμηση και επιτρέπει την εκτίμηση της αβεβαιότητας των προβλέψεων.

- **Support Vector Regressor (SVR):** είναι κατάλληλο για προβλήματα παλινδρόμησης με μη γραμμικά όρια απόφασης, ιδιαίτερα σε σύνολα δεδομένων περιορισμένου μεγέθους.

- **Elastic Net:** γραμμικό μοντέλο παλινδρόμησης με κανονικοποίηση, το οποίο συνδυάζει τις ποινές L1 και L2 και προσφέρει ανθεκτικότητα σε πολυσυγγραμμικότητα.

Για τη βελτιστοποίηση της απόδοσης των παραπάνω μοντέλων, πραγματοποιήθηκε ρύθμιση των υπερ παραμέτρων με τη χρήση της μεθόδου **Randomized Search Cross-Validation** (RandomizedSearchCV). Η συγκεκριμένη μέθοδος είναι πιο κατάλληλη συγκριτικά με την εξαντλητική αναζήτηση (Grid Search), καθώς επιτρέπει την αποδοτική εξερεύνηση του χώρου των υπερ παραμέτρων με μειωμένο υπολογιστικό κόστος και χωρίς σημαντική απώλεια στην ποιότητα των αποτελεσμάτων.

Η διαδικασία της αναζήτησης πραγματοποιήθηκε εντός κάθε fold της K-Fold, χρησιμοποιώντας αποκλειστικά τα δεδομένα εκπαίδευσης. Για κάθε μοντέλο ορίστηκε ένα σύνολο υπερπαραμέτρων, το οποίο διερευνήθηκε μέσω τυχαίας δειγματοληψίας περιορισμένου αριθμού συνδυασμών. Με αυτό τον τρόπο διασφαλίζεται ότι τα δεδομένα ελέγχου δεν επηρεάζουν την επιλογή των βελτιστων υπερπαραμέτρων.
Η χρήση του inner cross-validation στο πλαίσιο του RandomizedSearchCV συμβάλλει στην μείωση του κινδύνου για overfitting και οδηγεί σε πιο αξιόπιστα και γενικεύσιμα μοντέλα. Μετά την ολοκλήρωση της διαδικασίας αναζήτησης, επιλέχθηκε το μοντέλο με τις βέλτιστες υπερπαραμέτρους και χρησιμοποιήθηκε για την παραγωγή προβλέψεων τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο ελέγχου κάθε fold.

3.5 ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ (RMSE,MAE,Max Error,MAP)

Για την ποσοτική αξιολόγηση της απόδοσης των μοντέλων παλινδρόμησης χρησιμοποιήθηκε ένα σύνολο τεσσάρων συμπληρωματικών μετρικών.

- **Root Mean Squared Error (RMSE)**
  Το RMSE υπολογίζει τη τετραγωνική ρίζα του μέσου τετραγωνικού σφάλματος μεταξύ των πραγματικών και των προβλεπόμενων τιμών. Δίνει μεγαλύτερη έμφαση στα μεγάλα σφάλματα, γεγονός που το καθιστά ιδιαίτερα χρήσιμο σε εφαρμογές όπου οι μεγάλες αποκλίσεις θεωρούνται κρίσιμες. Οπως φαίνεται στη βιβλιογραφία της παλινδρόμησης χρησιμοποιείται ευρέως και παρέχει μέτρηση σφάλματος στην ίδια κλίμακα με τη μεταβλητή στόχο.

- **Mean Absolute Error (MAE)**
  Το MAE υπολογίζει τον μέσο όρο των απόλυτων σφαλμάτων και προσφέρει μια πιο ανθεκτική μέτρηση σε ακραίες τιμές σε σχέση με το RMSE. Αντιπροσωπεύει τη μέση απόκλιση των προβλέψεων απο τις πραγματικές τιμές και είναι εύκολα ερμηνεύσιμο, καθώς εκφράζεται στην ίδια μονάδα μέτρησης με το target.

- **Maximum Error (Max Error)**
  Η μετρική Max Error μετρά το μέγιστο απόλυτο σφάλμα που παρατηρείται μεταξύ των προβλέψεων και των πραγματικών τιμών. Παρέχει πληροφορία για το χειρότερο δυνατό σενάριο απόδοσης του μοντέλου, κάτι που είναι ιδιαίτερα σημαντικό σε ιατρικές εφαρμογές, όπου μεμονωμένες μεγάλες αποκλίσεις μπορεί να έχουν σοβαρές επιπτώσεις.

- **Mean Absolute Percentage Error (MAPE)**
  Το MAPE υπολογίζει το μέσο απόλυτο ποσοστιαίο σφάλμα και εκφράζει την απόδοση του μοντέλου σε ποσοστιαία κλίμακα. Η συγκεκριμένη μετρική είναι ιδιαίτερα διαισθητική, καθώς επιτρέπει την άμεση κατανόηση του σχετικού μεγέθους σφάλματος σε σχέση με τις πραγματικες τιμές. Για την αποφυγή αριθμητικών

προβλημάτων, εφαρμοστης μικρή σταθερά στον παρονομαστή κατά τον υπολογισμό της μετρικής.

Οι παραπάνω μετρικές σφάλματος υπολογίστηκαν τόσο στην κανονικοποιημένη κλίμακα της μεταβλητής στόχου όσο και μετά την επαναφορά των προβλέψεων στο πραγματικό εύρος τιμών (denormalization). Συγκεκριμένα, οι μετρικές αξιολόγησης υπολογίστηκαν ξεχωριστά για το σύνολο εκπαίδευσης και το σύνολο ελέγχου κάθε fold του cross-validation. Με τον τρόπο αυτό καθίσταται δυνατή η ταυτόχρονη αξιολόγηση της ακρίβειας των μοντέλων κατα την εκπαίδευση, καθώς και της ικανότητας τους να γενικεύουν σε μη εμφανίσμένα δεδομένα, επιτρέποντας μια αξιόπιστη και ολοκληρωμένη συγκριτική ανάλυση .

3.6 EXPLAINABILITY ΜΕ SHAP

Στην παρούσα εργασία εφαρμόστηκε η μέθοδος ερμηνευσιμότητας βασισμένη στο πλαίσιο **SHAP(SHapley Additive exPlanations)** για τον λόγο ότι η χρήση σύνθετων και μη γραμμικών μοντέλων παλινδρόμησης, όπως τα Random Forest, τα Gaussian Processes και οι Support Vector Regressor, συνοδεύονται συχνά από μειωμένη ερμηνευσιμότητα των παραγόμενων προβλέψεων. Ωστόσο, σε εφαρμογές στον τομέα της υγείας και η κατανόηση των παραγόντων που επηρεάζουν τις πρόβλεψης ενός μοντέλου είναι εξίσου σημαντικά με την ακρίβεια των αποτελεσμάτων. Η μέθοδος SHAP βασίζεται στη θεωρία παιγνίων και συγκεκριμένα στις τιμές Shapley, παρέχοντας μια ενιαία και θεωρητικά τεκμηριωμένη προσέγγιση για την αποτίμηση της συνεισφοράς κάθε χαρακτηριστικού στην τελική πρόβλεψη ενός μοντέλου.

Στο πλαίσιο των πειραμάτων, για κάθε μοντέλο και για κάθε fold του cross-validation, δημιουργήθηκε ένας SHAP explainer βασισμένος στη συνάρτηση πρόβλεψης του train set. Ως σύνολο αναφοράς (background dataset) χρησιμοποιήθηκε τυχαίο υποσύνολο των δεδομένων εκπαίδευσης κάθε fold, προκειμένου να διασφαλιστεί η υπολογιστική αποδοτικότητα της μεθόδου. Για την παγκόσμια ερμηνεία των μοντέλων, δημιουργήθηκαν **SHAP summary plots**, τα οποία απεικονίζουν τη σχετική σημασία κάθε χαρακτηριστικού και τη επίδραση του στις προβλέψεις. Παράλληλα, για την τοπική ερμηνεία παρήχθησαν **SHAP waterfall plots** για δύο επιλεγμένα δείγματα από το σύνολο ελέγχου κάθε fold, αναδεικνύοντας τη συνεισφορά κάθε μεταβλητής στην τελική τιμή πρόβλεψης.

Η ενσωμάτωση της μεθόδου SHAP στην πειραματική διαδικασία επιτρέπει τη μετατροπή των μοντέλων “black box” σε ερμηνεύσιμα εργαλεία, ενισχύοντας την αξιοπιστία και τη διαφάνεια των αποτελεσμάτων. Αυτή η προσέγγιση είναι ιδιαίτερα σημαντική σε ιατρικά προβλήματα πρόβλεψης όπου η ερμηνεία των αποφάσεων του μοντέλου μπορεί να υποστηρίξει την κατανόηση της νόσου αλλα και να διευκολύνει τη λήψη τεκμηριωμένων κλινικών αποφάσεων.

4. ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ

4.1 ΠΕΙΡΑΜΑΤΙΚΗ ΔΙΑΔΙΚΑΣΙΑ

Για την αξιολόγηση των μοντέλων εφαρμόστηκε διαδικασία 6-fold cross validation. Σε κάθε fold, τα δεδομένα χωρίστηκαν σε σύνολα εκπαίδευσης και ελέγχου, ενώ η επιλογή των βέλτιστων υπερπαραμέτρων πραγματοποιήθηκε αποκλειστικά στο σύνολο εκπαίδευσης μέσω RandomizedSearchCV.

4.2 ΣΥΓΚΕΝΤΡΩΤΙΚΑ ΑΡΙΘΜΗΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ

Ο πίνακας παρουσιάζει τις μέσες τιμές (mean) και τις τυπικές αποκλίσεις (std) των παραμέτρων test set, υπολογισμένες πάνω στα 6 fold

	RMSE		MAE		MAPE		Max	
	mean	std	mean	std	mean	std	mean	std
Model								
ElasticNet	55.514709	3.827822	45.657681	4.666013	41.231013	7.278469	130.389042	9.929462
GaussianProcess	58.139259	6.699544	45.725138	5.509333	39.497357	6.148810	177.945345	27.767047
RandomForest	56.941428	5.035686	46.743746	4.907919	40.962264	5.212293	141.039320	12.037944
SVR	55.316002	4.865833	44.496443	4.865562	38.879432	6.081816	146.984095	11.763688

Πινακας 1: Μέσος όρος και τυπική απόκλιση των σφαλμάτων (6-fold)

- Με κριτήριο το **RMSE(mean)**, το **SVR** εμφανίζει την καλύτερη μέση επίδοση **(55.316)**, με πολύ κοντινή επίδοση απο το **ElasticNet (55.515)**
- Με κριτήριο το **MAE**, το **SVR** είναι επίσης καλύτερο **(44.496)**, άρα κατά μέσο όρο κάνει μικρότερη απόλυτη απόκλιση.
- Με κριτήριο το **MAPE**, το **SVR** έχει το μικρότερο ποσοστιαίο σφάλμα **(33.879%),** γεγονός που το κάνει πιο αποδοτικό σε σχέση με την κλίμακα σφάλματος.
- Στο **Max Error**, το **ElasticNet,** εμφανίζει το μικρότερο μέσο μέγιστο σφάλμα **(130.389)**, δηλαδή περιορίζει καλύτερα τα ακραία λάθη. Αντίθετα, το **GaussianProcess** έχει σημαντικά μεγαλύτερο **Max (177.945)** και υψηλή διακύμανση **(std 27.767)**, που δείχνει μικρότερη σταθερότητα σε ακραίες περιπτώσεις.

Συνολικά, το SVR αναδεικνύεται ως το πιο ισορροπημένο μοντέλο ως προς RMSE/MAE/MAPE, ενώ το ElasticNet φαίνεται να περιορίζει καλύτερα τις χειρότερες προβλέψεις (Max Error).

*Εστω ότι παίρνουμε δειγματολιπτικά απο το fold1

4.3 ΟΠΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ

Για ποιοτικό έλεγχο δημιουργήθηκαν γραφήματα Actual(true) vs Predicted , ένα ανά μοντέλο. Σε κάθε γράφημα, όσο πιο κοντά βρίσκονται τα σημεία στη διαγώνιο y = x, τόσο καλύτερη είναι η προσαρμογή.

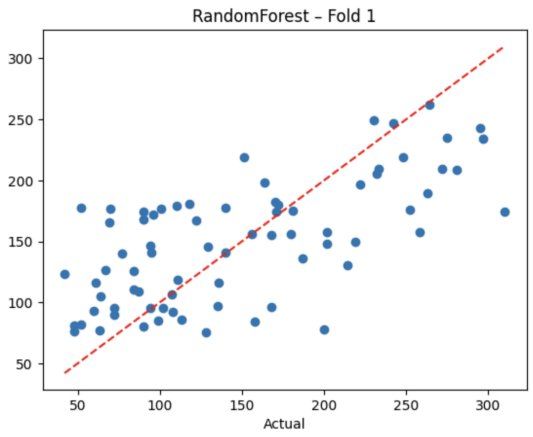

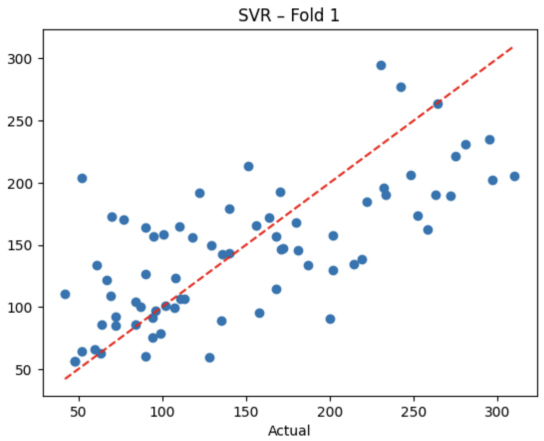

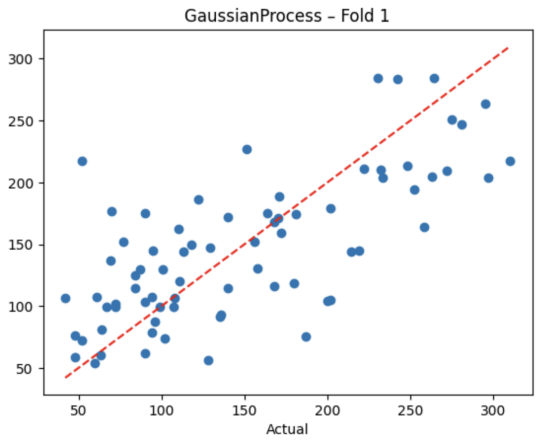

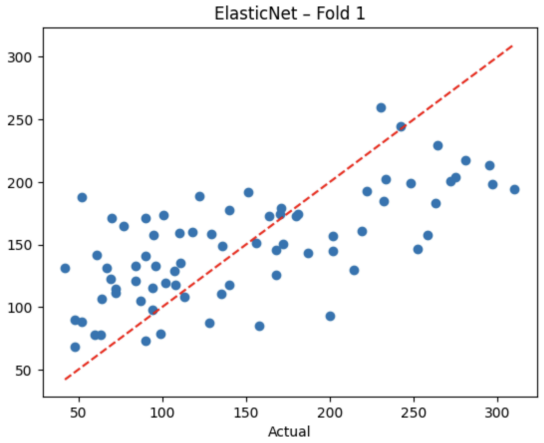

Γενικά παρατηρείται μεγαλύτερη διασπορά σε υψηλές τιμές στόχου, που είναι σύνηθες στο Diabetes dataset, καθώς οι ακραίες περιπτώσεις είναι δυσκολότερο να προβλεφθουν. Το μοντέλο με οπτικά πιο πυκνή συγκέντρωση γύρω από την διαγώνιο στο fold 1 συνήθως συμφωνεί και με το καλύτερο RMSE.

4.4 ΕΡΜΗΝΕΥΣΙΜΟΤΗΤΑ ΜΕ SHAP

A. SHAP Summary plot
B. SHAP Waterfall plots

A. SHAP Summary plot

Τα SHAP summary plots απεικονίζουν τη συνολική επίδραση κάθε χαρακτηριστικού στην τελική πρόβλεψη.

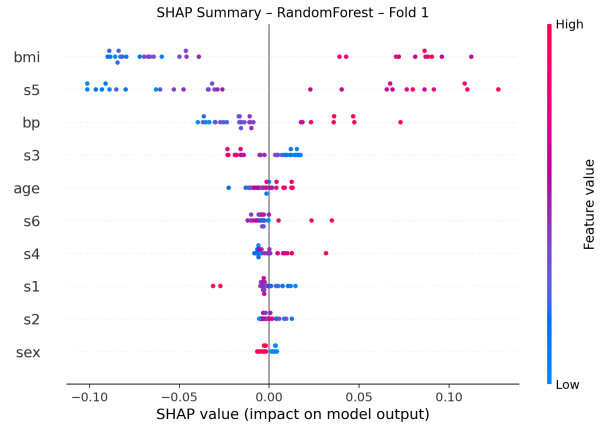

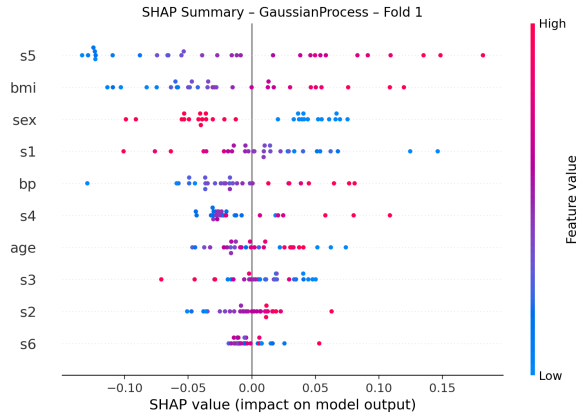

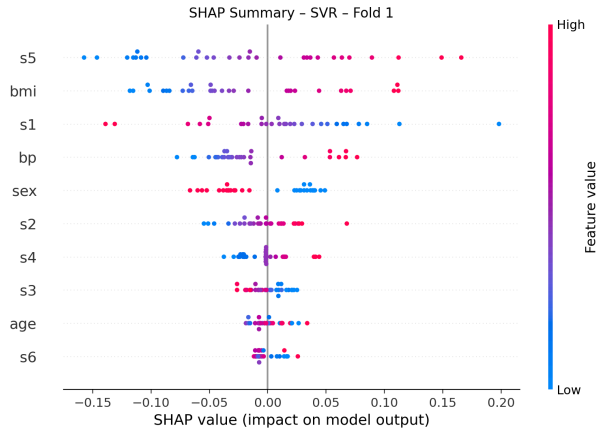

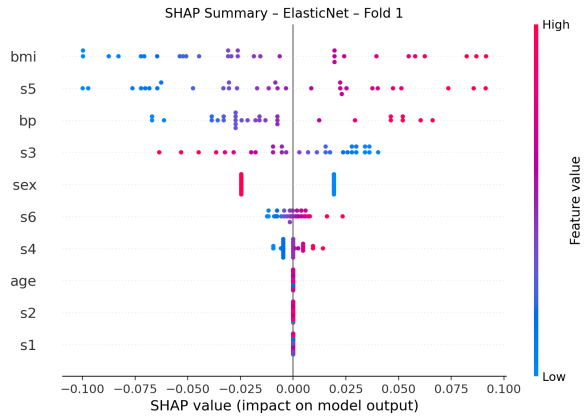

Random Forest – SHAP Summary (Fold 1):

Για το μοντέλο Random Forest, το χαρακτηριστικό **BMI** εμφανίζεται ως το σημαντικότερο, με υψηλές τιμές του να οδηγούν κυρίως σε αύξηση της προβλεπόμενης εξέλιξης της νόσου. Ακολουθούν τα χαρακτηριστικά **s5** και **bp**, τα οποία επίσης παρουσιάζουν ισχυρή θετική συνεισφορά. Η σχετικά μεγάλη διασπορά των SHAP τιμών υποδηλώνει μη γραμμική συμπεριφορά και αλληλεπιδράσεις μεταξύ των χαρακτηριστικών, χαρακτηριστικό γνώρισμα των δενδρικών μοντέλων.

Gaussian Process – SHAP Summary (Fold 1)

Στο μοντέλο Gaussian Process, παρατηρείται ότι τα χαρακτηριστικά **s5** και **BMI** έχουν τη μεγαλύτερη επίδραση στην πρόβλεψη. Η κατανομή των SHAP τιμών εμφανίζεται πιο ομαλή σε σύγκριση με το Random Forest, γεγονός που αντανακλά την πιθανοτική φύση του μοντέλου. Επιπλέον, η μεταβλητή **sex** παρουσιάζει σαφή διαφοροποίηση στην επίδρασή της, γεγονός που υποδηλώνει ότι το μοντέλο ενσωματώνει λεπτές μη γραμμικές σχέσεις.

SVR – SHAP Summary (Fold 1)

Για το μοντέλο SVR, τα χαρακτηριστικά **s5** και **BMI** παραμένουν τα πιο σημαντικά, ωστόσο η κατανομή των SHAP τιμών είναι πιο συμμετρική γύρω από το μηδέν. Αυτό υποδηλώνει πιο ομαλή και σταθερή συμπεριφορά του μοντέλου, με λιγότερες ακραίες προβλέψεις. Το χαρακτηριστικό **s1** εμφανίζει σημαντική αλλά αντίθετης κατεύθυνσης επίδραση για διαφορετικές τιμές, γεγονός που υποδεικνύει μη γραμμική σχέση.

ElasticNet – SHAP Summary (Fold 1)

Το γραμμικό μοντέλο ElasticNet παρουσιάζει σαφέστερη και πιο περιορισμένη κατανομή SHAP τιμών. Το **BMI** και το **s5** αποτελούν τα κυρίαρχα χαρακτηριστικά, με την επίδρασή τους να είναι σχεδόν γραμμική. Τα υπόλοιπα χαρακτηριστικά παρουσιάζουν μικρότερη συνεισφορά, γεγονός που συμφωνεί με τη φύση του μοντέλου και τη χρήση κανονικοποίησης (regularization).

Συνολικά παρατηρείται συνέπεια των μοντέλων ως προς τη σημασία των χαρακτηριστικών **BMI** και **s5**, τα οποία αναγνωρίζονται ως τα πιο καθοριστικά. Ωστόσο, τα μη γραμμικά μοντέλα (Random Forest, Gaussian Process, SVR) εμφανίζουν μεγαλύτερη διασπορά στις SHAP τιμές, υποδηλώνοντας την ικανότητά τους να αποτυπώνουν πιο σύνθετες σχέσεις, σε αντίθεση με το ElasticNet που παρέχει πιο ερμηνεύσιμες αλλά λιγότερο ευέλικτες προβλέψεις.

B. SHAP Waterfall plots

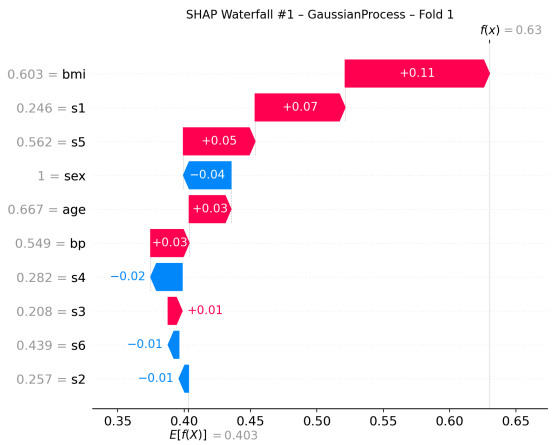

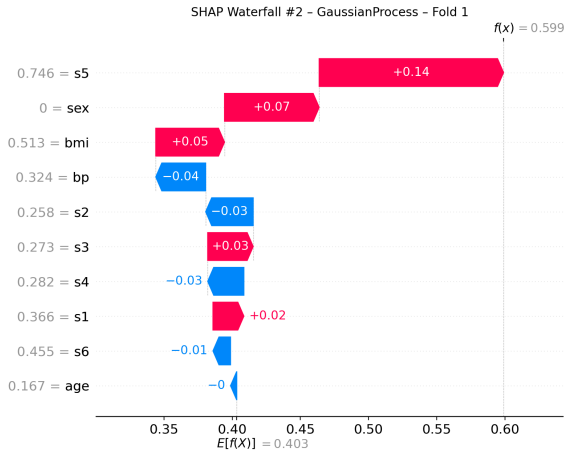

Τα SHAP waterfall plots παρουσιάζουν αναλυτικά πώς κάθε χαρακτηριστικό συνεισφέρει στη συγκεκριμένη πρόβλεψη, ξεκινώντας από τη μέση τιμή του μοντέλου.

Τα SHAP waterfall plots απεικονίζουν την ερμηνεία μιας *συγκεκριμένης* πρόβλεψης. Η τιμή βάσης E[f(X)] εκφράζει τον μέσο όρο των προβλέψεων του μοντέλου στο background δείγμα. Στη συνέχεια, κάθε χαρακτηριστικό μετατοπίζει την πρόβλεψη προς τα πάνω (κόκκινο, θετική συνεισφορά) ή προς τα κάτω (μπλε, αρνητική συνεισφορά) μέχρι να προκύψει η τελική τιμή f(x).

Τα δύο παραδείγματα επιβεβαιώνουν τα ευρήματα των SHAP summary plots. Τα **bmi** και **s5** εμφανίζονται συστηματικά ως οι ισχυρότεροι παράγοντες που ωθούν την πρόβλεψη προς υψηλότερες τιμές, ενώ άλλα χαρακτηριστικά (π.χ. bp, s4, s6) λειτουργούν συχνά διορθωτικά/αντιστάθμισης, μειώνοντας την τελική εκτίμηση.

5. ΣΥΜΠΕΡΑΣΜΑΤΑ

Στην παρούσα εργασία πραγματοποιήθηκε συγκριτική αξιολόγηση τεσσάρων διαφορετικών μοντέλων ElasticNet, Gaussian Process Regression, Random Forest και Support Vector Regression (SVR), με χρήση διαστρωματωμένης cross-validation και πολλαπλών μετρικών αξιολόγησης. Από τα συγκεντρωτικά πειραματικά αποτελέσματα προκύπτει ότι <u>κανένα μοντέλο δεν υπερέχει απόλυτα</u> σε όλες τις μετρικές, ωστόσο παρατηρούνται σαφείς τάσεις. Το **SVR** και το **ElasticNet** εμφανίζουν τις χαμηλότερες μέσες τιμές **RMSE** και **MAE**, γεγονός που υποδεικνύει καλή συνολική ακρίβεια και σταθερότητα. Το **Gaussian Process** παρουσιάζει αυξημένη διακύμανση και μεγαλύτερα μέγιστα σφάλματα, γεγονός που μπορεί να αποδοθεί στη μεγαλύτερη ευαισθησία του μοντέλου σε ακραίες παρατηρήσεις. Επίσης το **Random Forest** επιτυγχάνει ανταγωνιστική απόδοση, με σχετικά ισορροπημένη συμπεριφορά μεταξύ bias και variance. Όσον αφορά τη μετρική **MAPE**, το **SVR** εμφανίζει την καλύτερη μέση επίδοση, γεγονός που το καθιστά ιδιαίτερα ελκυστικό για εφαρμογές όπου η σχετική (ποσοστιαία) ακρίβεια έχει μεγαλύτερη σημασία από το απόλυτο σφάλμα.

Η ανάλυση ερμηνευσιμότητας με τη χρήση **SHAP** ανέδειξε με συνέπεια τη σημασία συγκεκριμένων χαρακτηριστικών. Σε όλα τα μοντέλα, το **BMI** και το **s5** εμφανίζονται ως οι πιο ισχυροί παράγοντες που επηρεάζουν την πρόβλεψη, επιβεβαιώνοντας και ευρήματα της σχετικής βιβλιογραφίας. Τα SHAP summary plots έδειξαν ότι υψηλές τιμές των χαρακτηριστικών αυτών οδηγούν συστηματικά σε υψηλότερες προβλέψεις της εξέλιξης της νόσου, ενώ άλλα χαρακτηριστικά (όπως bp, s4 και s6) λειτουργούν συχνά αντισταθμιστικά. Επιπλέον, τα SHAP waterfall plots κατέδειξαν ότι διαφορετικές προβλέψεις μπορεί να προκύπτουν μέσω διαφορετικών συνδυασμών χαρακτηριστικών, ακόμα και εντός του ίδιου μοντέλου.

Συνολικά, τα αποτελέσματα δείχνουν ότι απλούστερα μοντέλα όπως το ElasticNet μπορούν να επιτύχουν πιο ανταγωνιστική απόδοση απο πιο σύνθετα μοντέλα, όπως το Random Forest και το Gaussian Process τα οποία προσφέρουν μεν ευελιξία, αλλά με αυξημένη πολυπλοκότητα και μεταβλητότητα. Εν κατακλείδι η ενσωμάτωση τεχνικών ερμηνευσιμότητας, όπως το SHAP, αποδεικνύεται κρίσιμη για την κατανόηση των προβλέψεων και ενισχύει την αξιοπιστία των μοντέλων σε ιατρικές εφαρμογές.

6. ΒΙΒΛΙΟΓΡΑΦΙΑ

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. https://doi.org/10.1023/A:1010933404324

Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least angle regression. *The Annals of Statistics*, 32(2), 407-499. (Η βασική πηγή για το Diabetes Dataset).

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688. (Για την τεκμηρίωση του MAPE και των μετρικών σφάλματος).

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. (Η θεμελιώδης δημοσίευση για τη μέθοδο SHAP).

Molnar, C. (2020). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. (Διαθέσιμο στο: https://christophm.github.io/interpretable-ml-book/).

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press. (Διαθέσιμο στο: http://www.gaussianprocess.org/gpml/).

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... & SciPy 1.0 Contributors. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261-272.